



การวิเคราะห์และเตรียม
ข้อมูล

รายงาน Scopus

การวิเคราะห์และเตรียมข้อมูลสำหรับการวิเคราะห์
ข้อมูลจากฐานข้อมูล Scopus



ผู้จัดทำเนื้อหา



66011212032 นายพฤตมินันท์ ประเสริฐการ
66011212060 นายอภิชาติ ศรียุทธ
66011212104 นายธีรวัฒน์ ไชยปัญญา
66011212174 นายธนรัฐ กันยาเยี่ยม
66011212180 นายธีรภัทร ราชดุขฤ์



ภาพรวม Dataset

Scopus




**10 สาขาวิชาด้าน
คอมพิวเตอร์**

ครอบคลุม Software, AI,
Computer Vision, Computer
Graphics และสาขาอื่น ๆ อีก 6
สาขา




6,000 บทความรวม

600 บทความต่อสาขา
รวบรวมจากฐานข้อมูล
Scopus



**10 ไฟล์ CSV, 23
คอลัมน์**

คอลัมน์หลัก เช่น Authors,
Title, Year, Abstract,
Keywords



สาขาที่วิเคราะห์หลัก

Software, AI, Computer
Vision, Computer
Graphics & Design และ
อื่น ๆ

การสำรวจ ข้อมูลเบื้องต้น



ชนิดข้อมูล

Year และ Cited by เป็นตัวเลข (int64) คอลัมน์อื่น ๆ เป็นข้อความ



Missing Values

Missing Values สูงสุดที่คอลัมน์ Page start/end สูงถึง 74%



EID ซ้ำ

พบ EID ซ้ำ 295 รายการ แต่ไม่มีแถวที่ซ้ำกันทั้งหมด



ข้อมูลครบถ้วน

คอลัมน์ Title และ Abstract ไม่มีค่า Missing ทุกรอบความ



การทำความสะอาด

ข้อมูล (Data Cleaning)


6 ขั้นตอนหลักในการทำความสะอาดข้อมูล:

- สร้างคอลัมน์ Subject จากชื่อไฟล์ CSV
- ลบบทความที่มีมากกว่า 1 Subject ออก
- ลบ Title ที่ซ้ำกันออกจากชุดข้อมูล
- จัดการ Missing Values ใน Abstract ด้วย fillna และ strip
- ตัดข้อความ Copyright/License ที่ปรากฏใน Abstract
- กรองเฉพาะบทความภาษาอังกฤษด้วย langdetect



ผลกระทบจาก

การทำความสะอาดข้อมูล




จำนวนบทความลดลงจาก 6,000 บทความ เหลือ 5,342 บทความ (ลดลง 11%) โดยมีการลบบทความ และแถวซ้ำรวมทั้งสิ้น 658 แถว ซึ่งประกอบด้วย บทความที่มีมากกว่า 1 สาขา, Title ซ้ำ และบทความที่ไม่ใช่ภาษาอังกฤษ

กราฟข้อมูลดิบ - หลังทำความสะอาดข้อมูล




RECORDS PER SUBJECT – RAW VS CLEANED



ความสมบูรณ์ของข้อมูล (Missing Values)



สัดส่วนค่าว่าง (missing) ในคอลัมน์ข้อความหลักทั้ง 4 คอลัมน์ จากข้อมูลดิบก่อนทำความสะอาด



สัดส่วนข้อมูลที่มีค่าหายไปในแต่ละคอลัมน์ ได้แก่ Title, Abstract, Author Keywords และ Index Keywords โดยพบว่า Title และ Abstract ไม่มีค่าหายไป ขณะที่ Author Keywords มีค่าหายไปประมาณ 8% และ Index Keywords มีค่าหายไปประมาณ 13% ซึ่งเป็นคอลัมน์ที่มี Missing Values มากที่สุด

การกระจาย



ความยาว Title & Abstract



Histogram แสดงว่า Title มีความยาวเฉลี่ย 9–15 คำ ส่วน Abstract มีความยาวเฉลี่ย 150–300 คำ นอกจากนี้ยังวิเคราะห์ความยาวเฉลี่ยของ Title และ Abstract แยกตามสาขาวิชา เพื่อเปรียบเทียบรูปแบบการเขียนในแต่ละสาขา


สถิติ Keywords

จำนวน Author Keywords และ Index Keywords ต่อบทความ พร้อมสัดส่วนบทความที่ไม่มี keyword แยกตามสาขา




การกระจายจำนวน Keywords ของแต่ละบทความ โดย Author Keywords ซึ่งเป็นคำสำคัญที่ผู้เขียนกำหนดเอง มีจำนวนแตกต่างกันค่อนข้างมาก และมีบทความจำนวนหนึ่งที่ไม่มี Author Keywords ขณะที่ Index Keywords ซึ่งมาจากระบบจัดทำดัชนีของ Scopus มีจำนวนต่อบทความสูงกว่าอย่างชัดเจน

สถิติ Keywords



เปรียบเทียบจำนวน Author Keywords และ Index Keywords เฉลี่ยของแต่ละสาขาวิชา พบว่า Author Keywords มีความแตกต่างระหว่างสาขาไม่มากนัก โดยมีค่าเฉลี่ยประมาณ 4.4–5.9 คำต่อบทความ ในขณะที่ Index Keywords มีความแตกต่างมากกว่า โดย ComNetworks มีค่าเฉลี่ยสูงที่สุดประมาณ 24.89 คำ และ ComMath ต่ำที่สุดประมาณ 16.02 คำ

สัดส่วนบทความที่ไม่มี Keywords



เปรียบเทียบสัดส่วนบทความที่ไม่มี Author Keywords และ Index Keywords ในแต่ละสาขาวิชา พบว่าสาขา AI มีอัตราการไม่มี Keywords สูงเมื่อเปรียบเทียบกับหลายสาขา โดย Author Keywords ไม่มีข้อมูลประมาณ 24.4% และ Index Keywords ประมาณ 23.6% ในขณะที่บางสาขามีอัตราการไม่มี Keywords ต่ำกว่ามาก

คำที่พบบ่อย (Word Explorer)

เลือกสาขาวิชาเพื่อดู word cloud และคำ/keyword ที่พบบ่อยที่สุดในแต่ละคอลัมน์ข้อความ

SUBJECT

ทั้งหมด (All Subjects)

5,342 บาทถ้วน

TITLE – WORD CLOUD




ABSTRACT – WORD CLOUD




คำที่พบบ่อย (Word Explorer)


AUTHOR KEYWORDS – WORD CLOUD



INDEX KEYWORDS – WORD CLOUD





คำที่พบบ่อย (Word Explorer)



วิเคราะห์คำที่ปรากฏบ่อยที่สุดใน Title และ Abstract ของบทความทั้งหมด โดยใน Title คำว่า “learning” พบมากที่สุดจำนวน 646 ครั้ง ส่วนใน Abstract พบคำว่า “learning” จำนวน 3,325 ครั้ง


คำสำคัญที่พบบ่อย (Word Explorer)



การวิเคราะห์ความถี่ของคำใน Author Keywords และ Index Keywords เพื่อแสดงคำสำคัญที่พบบ่อยที่สุดในชุดข้อมูล โดย Author Keywords พบคำว่า "deep learning" มากที่สุด จำนวน 374 ครั้ง ความสำคัญ ส่วน Index Keywords พบคำ เช่น "deep learning", "human" และ "article" ในความถี่สูง


การเตรียมข้อมูล

Text Embedding



คอลัมน์ที่เลือกใช้

EID, Title, Abstract, Author
Keywords, Index Keywords, Subject




สร้าง embedding_text

รวม 4 คอลัมน์หลักด้วยตัวคั่น [SEP] เพื่อ
สร้าง embedding_text



โมเดลที่ใช้

SPECTER2 พร้อม Proximity Adapter
สำหรับงานด้านวิชาการ



การประมวลผล

GPU T4 บน Google Colab, batch
size 16, max_length 512 tokens

Feature Vector

และการแบ่งข้อมูล



ขนาด Feature Vector: 5,342 แถว $\times$ 768 มิติ จากโมเดล
SPECTER2

ใช้ L2-normalization เพื่อปรับขนาด Vector ให้เหมาะสม
แบ่งข้อมูลแบบ Stratified Sampling 80/20

→ Train set: 4,273 ตัวอย่าง

→ Test set: 1,069 ตัวอย่าง



ผลการทดสอบ


Logistic Regression

- **Accuracy:** 63.24%
- **F1-Score สูงสุด:**
Computational Mathematics (0.83),
Computer Graphics & Design (0.81)
- **F1-Score ต่ำสุด:**
CS Applications (0.29),
Information Systems (0.32)
- **Macro Avg:**
Precision 0.61,
Recall 0.62,
F1-score 0.61

Accuracy: 0.6323666978484564

	precision	recall	f1-score	support
scopus_export_Ai	0.56	0.65	0.60	100
scopus_export_ComGraphicsDesign	0.79	0.84	0.81	117
scopus_export_ComMath	0.78	0.89	0.83	117
scopus_export_ComNetworks	0.67	0.69	0.68	101
scopus_export_ComScienceApp	0.45	0.22	0.29	110
scopus_export_ComVision	0.58	0.84	0.69	115
scopus_export_Hardware	0.67	0.70	0.68	108
scopus_export_HumanComInteraction	0.55	0.51	0.53	103
scopus_export_InformationSystems	0.41	0.26	0.32	96
scopus_export_Software	0.65	0.63	0.64	102
accuracy		0.63		1069
macro avg	0.61	0.62	0.61	1069
weighted avg	0.62	0.63	0.61	1069

สรุปผลการ วิเคราะห์โมเดล




โมเดลมีประสิทธิภาพแตกต่างกันตามสาขาวิชา บาง
สาขายังต้องปรับปรุงข้อมูลหรือโมเดลเพิ่มเติม
แนวทางพัฒนาต่อไป: ขยายขนาดข้อมูล, ปรับแต่ง
พารามิเตอร์โมเดล และทดลองใช้โมเดลอื่นเพื่อเพิ่ม
ความแม่นยำ

การบันทึก ผลลัพธ์

ไฟล์ที่จัดเก็บและผลลัพธ์จากกระบวนการวิเคราะห์:

- specter2_embeddings.npy — ข้อมูล embedding ทั้งหมด ขนาด $5,342 \times 768$ มิติ พร้อมใช้งานสำหรับการวิเคราะห์ต่อ
- scopus_cleaned_with_embedding_text.csv — ข้อมูลบทความที่ผ่านการทำความสะอาดพร้อมคอลัมน์ embedding_text



ขอบคุณ

THANK YOU

